HUTECH
Đại học Công nghệ Tp.HCM

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ TP. HCM

ĐỒ ÁN CƠ SỞ

PHÂN CỤM KHÁCH SẠN DỰA TRÊN ĐẶC TÍNH VÀ CẢM XÚC CỦA KHÁCH HÀNG

Ngành: **CÔNG NGHỆ THÔNG TIN**
Chuyên ngành: **KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn: **Th.S Nguyễn Quang Phúc**
Sinh viên thực hiện: Nguyễn Đăng Khoa
MSSV: 2386400026 Lớp: 23DKHA1

TP. Hồ Chí Minh, 2026

NHẬN XÉT GIÁO VIÊN HƯỚNG DẪN

……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……

TP. Hồ Chí Minh, ngày ... tháng ... năm 2026

Giáo viên hướng dẫn

(Ký tên, đóng dấu)

Lời cam đoan

Tôi, Nguyễn Đăng Khoa xin cam đoan:

Đồ án "Phân cụm khách sạn dựa trên đặc tính và cảm xúc khách hàng" là công trình nghiên cứu và thực hiện của cá nhân tôi dưới sự hướng dẫn của giảng viên hướng dẫn.

Các dữ liệu, quy trình xử lý, kết quả thực nghiệm và nhận xét trong đồ án được thực hiện dựa trên quá trình tiền xử lý, xây dựng đặc trưng và phân cụm dữ liệu đánh giá khách sạn. Những nội dung tham khảo từ tài liệu, bài báo, trang web hoặc nguồn khác đều được trích dẫn và liệt kê trong phần tài liệu tham khảo theo đúng quy định.

Tôi cam đoan không sao chép nội dung từ công trình của người khác để đưa vào đồ án của mình. Các kết quả phân tích, bảng biểu và hình ảnh trong đồ án phản ánh đúng quá trình thực hiện đề tài. Nếu có sai sót hoặc vi phạm về tính trung thực học thuật, tôi xin chịu hoàn toàn trách nhiệm trước nhà trường và giảng viên hướng dẫn.

TP. Hồ Chí Minh, ngày …… tháng …… năm 2026

Sinh viên thực hiện

Nguyễn Đăng Khoa

MỤC LỤC

CHƯƠNG 1. TỔNG QUAN 1
1.1. Giới thiệu đề tài 1
1.2. Nhiệm vụ đề tài 1
1.2.1. Tính cấp thiết của đề tài 2
1.2.2. Ý nghĩa thực tiễn của đề tài 2
1.3. Mục tiêu nghiên cứu 3
1.3.1. Mục tiêu tổng quát 3
1.3.2. Mục tiêu cụ thể 3
1.4. Đối tượng và phạm vi nghiên cứu 4
1.4.1. Đối tượng nghiên cứu 4
1.4.2. Phạm vi nghiên cứu 4
1.5. Phương pháp nghiên cứu 5
1.6. Đóng góp của đề tài 5
1.6.1. Đóng góp về mặt nghiên cứu 5
1.6.2. Đóng góp về mặt ứng dụng 6
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT 7
2.1. Dữ liệu văn bản 7
2.1.1. Khái niệm dữ liệu văn bản 7
2.1.2. Đặc điểm của dữ liệu văn bản 7
2.2. Xử lý ngôn ngữ tự nhiên 8
2.2.1. Khái quát về xử lý ngôn ngữ tự nhiên 8
2.2.2. Các bước xử lý văn bản cơ bản 8
2.2.3. Đặc điểm của dữ liệu đa ngôn ngữ 9
2.3. Phân tích cảm xúc 9
2.4. Phân tích cảm xúc theo khía cạnh 10
2.4.1. Khái niệm aspect 10
2.4.2. Nguyên lý phân tích cảm xúc theo khía cạnh 10
2.5. Embedding văn bản 10
2.5.1. Khái niệm embedding văn bản 10
2.5.2. Embedding đa ngôn ngữ 11
2.5.3. Mô hình Multilingual-E5-Large 11
2.6. Đặc trưng dữ liệu 12
2.6.1. Khái niệm đặc trưng dữ liệu 12
2.6.2. Kết hợp dữ liệu số và dữ liệu văn bản 13
2.6.3. RobustScaler 13
2.7. Giảm chiều dữ liệu bằng PCA 14
2.7.1. Khái niệm giảm chiều dữ liệu 14
2.7.2. Nguyên lý của PCA 14
2.7.3. Tỷ lệ phương sai giữ lại 14

2.8. Các thuật toán phân cụm 15
2.8.1. KMeans 15
2.8.2. Agglomerative Clustering 15
2.8.3. Gaussian Mixture Model 16
2.8.4. DBSCAN 16
2.9. Các chỉ số đánh giá phân cụm 17
2.9.1. Silhouette Score 17
2.9.2. Davies-Bouldin Index 17
2.9.3. Calinski-Harabasz Index 18
2.9.4. Inertia và Elbow Method 18
CHƯƠNG 3. PHƯƠNG PHÁP THỰC NGHIỆM 19
3.1. Tổng quan quy trình thực hiện 19
3.2. Dữ liệu đầu vào 20
3.3. Tiền xử lý dữ liệu review 20
3.4. Tạo embedding cho review 21
3.5. Gán topic và aspect 22
3.6. Xây dựng đặc trưng cấp khách sạn 23
3.7. Chuẩn bị đặc trưng khách sạn cho phân cụm 25
3.8. Phân cụm 26
CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM 27
4.1. Môi trường và cấu hình thực nghiệm 27
4.1.1. Môi trường thực nghiệm 27
4.1.2. Cấu hình thực nghiệm chính 27
4.2. Kết quả phân cụm khách sạn 28
4.2.1. So sánh các thuật toán phân cụm 28
4.2.2. Phân tích lựa chọn số cụm K 29
4.2.3. Cấu hình mô hình phân cụm cuối 29
4.2.4. Trực quan hóa kết quả phân cụm 30
4.3. Diễn giải đặc điểm các cụm khách sạn 31
4.3.1. Hồ sơ tổng quan của từng cụm 31
4.3.2. Diễn giải cụm theo sentiment và rating 32
4.3.3. Diễn giải cụm theo aspect 32
4.3.4. Tóm tắt ý nghĩa các cụm 34
4.4. Nhận xét chung về kết quả thực nghiệm 34
CHƯƠNG 5. KẾT LUẬN VÀ KIẾN NGHỊ 35
5.1. Kết luận 35
5.2. Hạn chế 36
5.3. Kiến nghị 36
TÀI LIỆU THAM KHẢO 37

DANH MỤC CÁC KÝ HIỆU, CÁC CHỮ VIẾT TẮT

Ký hiệu, chữ viết tắt	Ý nghĩa
NLP	Natural Language Processing
PCA	Principal Component Analysis
GMM	Gaussian Mixture Model
DBSCAN	Thuật toán phân cụm dựa trên mật độ
KMeans	Thuật toán phân cụm KMeans
E5	Mô hình embedding thuộc nhóm Embeddings from bidirectional Encoder rEpresentations
Multilingual-E5-Large	Mô hình embedding đa ngôn ngữ dùng để biểu diễn review
MongoDB	Hệ quản trị cơ sở dữ liệu NoSQL dùng để lưu dữ liệu
JSON	Định dạng dữ liệu dùng để lưu trữ và trao đổi dữ liệu
CSV	Định dạng tệp dữ liệu dạng bảng
GPU	Bộ xử lý đồ họa, dùng để tăng tốc bước tạo embedding
HTML	Ngôn ngữ đánh dấu siêu văn bản
URL	Địa chỉ tài nguyên trên Internet
Review	Nhận xét hoặc đánh giá của khách hàng
Sentiment	Cảm xúc hoặc thái độ trong đánh giá
IQR	Khoảng tứ phân vị, được tính bằng Q3 trừ Q1
Silhouette Score	Chỉ số đánh giá mức độ phù hợp của điểm dữ liệu với cụm
Davies-Bouldin Index	Chỉ số đánh giá độ chặt và độ tách biệt của cụm
Calinski-Harabasz Index	Chỉ số đánh giá tỷ lệ giữa độ tách cụm và độ chặt trong cụm
Inertia	Tổng bình phương khoảng cách từ điểm dữ liệu đến tâm cụm gần nhất
K	Số cụm trong thuật toán phân cụm
eps	Bán kính lân cận trong DBSCAN
min_samples	Số điểm tối thiểu để xác định điểm lõi trong DBSCAN
d	Văn bản đầu vào
E	Mô hình embedding
v_d	Vector biểu diễn của văn bản d
v_i,, v_j	Hai vector văn bản cần so sánh
R^k	Không gian vector k chiều
x	Giá trị của một đặc trưng hoặc một điểm dữ liệu
x_scaled	Giá trị đặc trưng sau khi chuẩn hóa
$median(x)$	Trung vị của đặc trưng x
$Q1, Q3$	Phân vị thứ nhất và phân vị thứ ba
λ_i	Trị riêng ứng với thành phần chính thứ i trong PCA
C_i	Cụm thứ i
μ_i	Tâm cụm thứ i

DANH MỤC BẢNG BIỂU

Bảng 3.1. Thống kê dữ liệu đầu vào.....20
Bảng 3.2. Danh sách aspect được xét.....22
Bảng 3.3. Nhóm đặc trưng cấp khách sạn.....24
Bảng 3.4. Cấu hình dữ liệu đầu vào cho phân cụm.....25
Bảng 3.5. Các thuật toán và chỉ số đánh giá được dùng.....26
Bảng 4.1. Môi trường thực nghiệm.....27
Bảng 4.2. Cấu hình thực nghiệm chính.....28
Bảng 4.3. Kết quả so sánh các cấu hình phân cụm tiêu biểu.....28
Bảng 4.4. Cấu hình mô hình phân cụm cuối.....30
Bảng 4.5. Hồ sơ trung bình của từng cụm.....31
Bảng 4.6. Điểm mạnh và điểm yếu của từng cụm theo aspect.....33
Bảng 4.7. Tóm tắt ý nghĩa các cụm khách sạn.....34

DANH MỤC HÌNH, VẼ ĐỒ THỊ

Hình 3.1. Quy trình thực nghiệm của đề tài.....19
Hình 3.2. Quy trình tạo embedding, topic và aspect.....21
Hình 3.3. Quy trình gán topic và aspect.....23
Hình 4.1. Biểu đồ Elbow của KMeans.....29
Hình 4.2. Số lượng khách sạn theo cụm.....30
Hình 4.3. Trực quan hóa cụm trên không gian PCA 2D.....31
Hình 4.4. So sánh sentiment và rating giữa các cụm.....32
Hình 4.5. Heatmap aspect được khen theo cụm.....32
Hình 4.6. Heatmap aspect bị chê theo cụm.....33

CHƯƠNG 1. TỔNG QUAN

1.1. Giới thiệu đề tài

Trên các nền tảng đặt phòng trực tuyến, đánh giá của khách hàng là nguồn dữ liệu phản ánh trực tiếp trải nghiệm lưu trú. Mỗi khách sạn thường có điểm rating, nhận xét tích cực, nhận xét tiêu cực và các tiêu chí dịch vụ. Các thông tin này cho biết khách hàng đánh giá ra sao về phòng, vệ sinh, vị trí, thái độ phục vụ, giá cả, wifi, tiếng ồn và quá trình check-in. Điểm rating trung bình giúp nhìn nhanh mức độ hài lòng chung, nhưng chưa mô tả đầy đủ chất lượng trải nghiệm. Hai khách sạn có cùng mức điểm vẫn nhận phản hồi khác nhau. Một khách sạn nhận lời khen về vị trí nhưng nhận đánh giá thấp về phòng ốc. Khách sạn khác có dịch vụ tốt hơn nhưng gặp nhiều phản hồi về wifi hoặc tiếng ồn.

Sự thiếu hụt thông tin từ điểm số định hướng nghiên cứu kết hợp dữ liệu định lượng với nội dung nhận xét bằng văn bản. Nghiên cứu "Phân cụm Khách sạn dựa trên đặc tính và cảm xúc của Khách hàng" xây dựng quy trình phân tích dữ liệu khách sạn theo hướng có khả năng diễn giải. Quy trình kết hợp điểm đánh giá, số lượng review, tiêu chí dịch vụ, độ đa dạng quốc gia của khách hàng, cảm xúc và nội dung khen, chê trong nhận xét để tạo bộ đặc trưng đại diện cho từng khách sạn. Trên bộ đặc trưng đó, các thuật toán phân cụm tìm ra những nhóm khách sạn có đặc điểm gần nhau. Mỗi nhóm sau đó được phân tích bằng rating, sentiment và aspect nhằm nhận diện nhóm có phản hồi tích cực, nhóm có trải nghiệm trung bình và nhóm còn nhiều điểm cần cải thiện.

1.2. Nhiệm vụ đề tài

Nghiên cứu xây dựng quy trình phân cụm khách sạn từ dữ liệu đánh giá của khách hàng. Các nhiệm vụ chính gồm tổ chức dữ liệu, xử lý review, trích xuất thông tin từ nội dung nhận xét, xây dựng đặc trưng cấp khách sạn và áp dụng thuật toán phân cụm. Dữ liệu khách sạn và review được lưu trong MongoDB để phục vụ truy vấn và xử lý. Phần review được làm sạch, xác định cảm xúc, tạo nội dung đầu vào cho embedding và gán các khía cạnh khách hàng nhắc đến.

Kết quả từ quá trình xử lý văn bản được tổng hợp cùng điểm đánh giá, số lượng review và tiêu chí dịch vụ để tạo bộ đặc trưng đại diện cho từng khách sạn. Bộ đặc trưng này được chuẩn hóa, giảm chiều và đưa vào các thuật toán phân cụm. Kết quả được đánh giá bằng các chỉ số phù hợp và phân tích lại theo từng nhóm. Nhiệm vụ cuối của nghiên cứu là diễn giải ý nghĩa các cụm, từ đó làm rõ nhóm khách sạn nhận phản hồi tốt, nhóm ở mức trung bình và nhóm còn nhiều phản hồi tiêu cực.

1.2.1. Tính cấp thiết của đề tài

Khách hàng thường xem đánh giá trực tuyến trước khi chọn nơi lưu trú. Trên Booking.com, phần rating và nhận xét phản ánh kinh nghiệm của khách đã lưu trú. Nguồn dữ liệu này có giá trị vì khách hàng ghi lại trực tiếp những điểm họ hài lòng và chưa hài lòng sau khi trải nghiệm dịch vụ. Khối lượng review lớn làm cho việc đọc thủ công mất nhiều thời gian. Dữ liệu còn có nhiều ngôn ngữ do khách hàng đến từ nhiều quốc gia. Mỗi nhận xét chứa tín hiệu về cảm xúc và vấn đề dịch vụ, nên cách đọc riêng lẻ khó tạo ra cái nhìn tổng hợp.

Nhu cầu xử lý dữ liệu này đặt ra bài toán phân cụm dựa trên đặc tính và cảm xúc của khách hàng. Kết quả phân cụm hỗ trợ việc nhìn khách sạn theo nhóm, thay vì xem từng đối tượng riêng lẻ. Cách nhìn theo nhóm giúp người phân tích nhận diện khuynh hướng phản hồi, mức độ hài lòng và các vấn đề dịch vụ xuất hiện thường xuyên.

1.2.2. Ý nghĩa thực tiễn của đề tài

Nghiên cứu giúp dữ liệu đánh giá khách sạn trở nên dễ phân tích hơn. Thay vì dừng ở điểm rating, quy trình xử lý thêm phần cảm xúc và nội dung khen, chê trong review. Ở góc độ nghiên cứu, bài toán này kết hợp dữ liệu số và dữ liệu văn bản trong cùng một quy trình. Rating, tiêu chí dịch vụ và số lượng review cung cấp thông tin định lượng. Nội dung nhận xét cung cấp bối cảnh về trải nghiệm của khách hàng. Khi hai nguồn dữ liệu này được tổng hợp ở cấp khách sạn, mô hình có thêm cơ sở để gom nhóm các đối tượng có đặc điểm gần nhau.

Ở góc độ ứng dụng, kết quả phân cụm giúp nhận diện điểm mạnh và điểm yếu của từng nhóm khách sạn. Một nhóm có lợi thế về vị trí nhưng còn hạn chế về phòng.

Nhóm khác nhận nhiều phản hồi tốt về dịch vụ nhưng gặp phàn nàn về wifi hoặc tiếng ồn. Những nhận xét theo nhóm này hỗ trợ quá trình thảo luận kết quả thực nghiệm và đề xuất hướng cải thiện dịch vụ.

1.3. Mục tiêu nghiên cứu

1.3.1. Mục tiêu tổng quát

Mục tiêu tổng quát của nghiên cứu là xây dựng quy trình phân cụm khách sạn dựa trên dữ liệu đánh giá của khách hàng. Quy trình này kết hợp đặc tính khách sạn, điểm đánh giá, cảm xúc và nội dung khen, chê trong review để tạo bộ đặc trưng đại diện cho từng khách sạn. Từ bộ đặc trưng đó, nghiên cứu gom nhóm các khách sạn có đặc điểm gần nhau. Mỗi cụm được phân tích lại bằng các đặc trưng gốc như rating, sentiment và aspect. Kết quả giúp mô tả các nhóm khách sạn theo trải nghiệm của khách hàng, thay vì dựa vào một điểm trung bình duy nhất.

1.3.2. Mục tiêu cụ thể

Nghiên cứu tổ chức dữ liệu khách sạn và review vào MongoDB, sau đó kiểm tra, thống kê và tiền xử lý để chuẩn bị cho các bước phân tích. Nội dung review được làm sạch, tạo văn bản đầu vào cho embedding, xác định cảm xúc và lọc các mẫu đủ điều kiện xử lý. Các review hợp lệ được mã hóa bằng Multilingual-E5-Large để tạo vector, hỗ trợ gán topic và aspect. Ở cấp khách sạn, các review được tổng hợp thành bộ đặc trưng gồm điểm đánh giá, số lượng review, tỷ lệ cảm xúc, tiêu chí dịch vụ và tỷ lệ khen, chê theo từng aspect.

Từ bộ đặc trưng, dữ liệu được chuẩn hóa, giảm chiều bằng PCA và đưa vào các thuật toán phân cụm như KMeans, Agglomerative Clustering, Gaussian Mixture Model và DBSCAN. Kết quả được đánh giá bằng Silhouette Score, Davies-Bouldin Index, Calinski-Harabasz Index và Inertia. Mục tiêu sau cùng là phân tích ý nghĩa từng cụm để nhận diện nhóm có phản hồi tích cực, nhóm có trải nghiệm trung bình và nhóm còn nhiều phản hồi tiêu cực.

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu là bộ dữ liệu khách sạn và review khách hàng từ Booking.com. Dữ liệu được cung cấp dưới dạng file JSON. Mỗi file chứa thông tin của một khách sạn như tên, địa chỉ, mô tả, điểm đánh giá, tổng số lượt đánh giá và các tiêu chí dịch vụ. Phần review gồm thông tin người đánh giá, quốc gia, ngày đánh giá, điểm số, loại phòng, thời gian lưu trú, nhóm khách, nhận xét tích cực và nhận xét tiêu cực.

Trong nghiên cứu, mỗi khách sạn là một đối tượng để phân cụm. Các review thuộc cùng một khách sạn được tổng hợp thành bộ đặc trưng chung, phản ánh điểm đánh giá, số lượng review, cảm xúc, quốc gia của khách hàng và các khía cạnh như phòng, vệ sinh, dịch vụ, vị trí, giá cả, tiện nghi, wifi, tiếng ồn và check-in.

1.4.2. Phạm vi nghiên cứu

Nghiên cứu tập trung vào bài toán phân cụm khách sạn dựa trên đặc tính và cảm xúc của khách hàng. Kết quả dùng để chia khách sạn thành các nhóm có đặc điểm gần nhau. Nghiên cứu không dự đoán rating, không xếp hạng theo tiêu chuẩn du lịch và không xây dựng hệ thống gợi ý đặt phòng. Dữ liệu được lưu trong MongoDB local, gồm thông tin tỉnh thành, khách sạn, review, đặc trưng cấp khách sạn và kết quả phân cụm.

Các review quá ngắn, thiếu nội dung hoặc không đủ điều kiện tạo embedding được loại khỏi bước phân tích văn bản để giảm nhiễu. Phạm vi xử lý tập trung vào rating, sentiment, aspect, tiêu chí dịch vụ, quốc gia của khách, nhóm khách và nội dung khen, chê. Sau khi tạo bộ đặc trưng, dữ liệu được chuẩn hóa, giảm chiều bằng PCA và đưa vào các thuật toán phân cụm. Kết quả được đánh giá bằng các chỉ số phân cụm và phân tích lại theo từng nhóm khách sạn.

1.5. Phương pháp nghiên cứu

Nghiên cứu thực hiện theo quy trình xử lý dữ liệu từ dữ liệu gốc đến kết quả phân cụm. Bộ dữ liệu được kiểm tra cấu trúc, sau đó lưu vào MongoDB local để quản lý thông tin tỉnh thành, khách sạn, review, đặc trưng và kết quả. Sau khi lưu trữ, dữ liệu được thống kê để nắm số lượng khách sạn, số lượng review, phân bố điểm đánh giá, quốc gia của khách, nhóm khách, loại phòng và các giá trị thiếu. Phần review được làm sạch, tạo văn bản đầu vào cho embedding và gán nhãn cảm xúc dựa trên điểm số.

Các review hợp lệ được mã hóa bằng Multilingual-E5-Large để tạo vector, hỗ trợ gán topic và aspect. Ở cấp khách sạn, các review được tổng hợp thành bộ đặc trưng gồm rating, sentiment, aspect, độ đa dạng quốc gia và tiêu chí dịch vụ. Bộ đặc trưng sau đó được chuẩn hóa, giảm chiều bằng PCA và đưa vào các thuật toán phân cụm như KMeans, Agglomerative Clustering, Gaussian Mixture Model và DBSCAN. Kết quả được đánh giá bằng các chỉ số phân cụm và phân tích lại theo rating, sentiment, aspect để làm rõ đặc điểm từng nhóm khách sạn.

1.6. Đóng góp của đề tài

1.6.1. Đóng góp về mặt nghiên cứu

Nghiên cứu xây dựng quy trình phân cụm khách sạn dựa trên dữ liệu review và các đặc tính dịch vụ. Quy trình bao gồm các bước tổ chức dữ liệu, tiền xử lý review, tạo embedding, gán aspect, xây dựng đặc trưng cấp khách sạn, phân cụm và đánh giá kết quả. Đóng góp chính nằm ở cách kết hợp dữ liệu số và dữ liệu văn bản. Rating phản ánh mức độ hài lòng chung, còn review cung cấp nội dung khen, chê theo từng khía cạnh. Khi hai nguồn dữ liệu này được tổng hợp ở cấp khách sạn, mô hình có cơ sở để nhận diện các nhóm có đặc điểm gần nhau.

Nghiên cứu áp dụng Multilingual-E5-Large cho dữ liệu review đa ngôn ngữ. Mô hình chuyển nội dung nhận xét thành vector, hỗ trợ bước gán topic, gán aspect và xây dựng đặc trưng.

1.6.2. Đóng góp về mặt ứng dụng

Phân cụm chia khách sạn thành các nhóm có đặc điểm tương đồng. Mỗi nhóm được phân tích theo rating, sentiment, tiêu chí dịch vụ và aspect. Cách trình bày này giúp người đọc thấy nhóm nào nhận nhiều phản hồi tích cực, nhóm nào ở mức trung bình và nhóm nào còn nhiều phàn nàn.

Phân tích theo cụm cũng hỗ trợ nhận diện điểm mạnh và điểm yếu của từng nhóm. Một nhóm có lợi thế về vị trí nhưng còn hạn chế về phòng. Nhóm khác được khen về dịch vụ nhưng bị chê về wifi hoặc tiếng ồn. Cách phân tích này giúp dữ liệu review dễ hiểu hơn khi trình bày trong báo cáo và khi thảo luận thực nghiệm.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Dữ liệu văn bản

2.1.1. Khái niệm dữ liệu văn bản

Dữ liệu văn bản là dạng dữ liệu được tạo ra từ ngôn ngữ tự nhiên của con người. Dạng dữ liệu này xuất hiện trong phản hồi, bình luận, nhận xét, mô tả và nhiều nội dung do người dùng tạo ra trên môi trường trực tuyến. Dữ liệu văn bản là dữ liệu không có cấu trúc cố định như bảng số liệu. Ý nghĩa nằm trong từ ngữ, thứ tự câu, ngữ cảnh và sắc thái biểu đạt.

Khác với dữ liệu định lượng, văn bản không thể đưa trực tiếp vào mô hình học máy. Một mô hình tính toán cần dữ liệu ở dạng số để đo khoảng cách, độ tương đồng hoặc phân tách nhóm. Dữ liệu văn bản thường phải đi qua các bước làm sạch, chuẩn hóa và biểu diễn số. Sau bước này, nội dung ngôn ngữ trở thành dữ liệu đầu vào cho các kỹ thuật phân tích.

Giá trị của văn bản nằm ở phần diễn giải phía sau các con số. Một điểm đánh giá cho biết mức độ hài lòng chung, còn phần nhận xét cho biết lý do phía sau mức điểm đó. Một điểm đánh giá cho biết mức độ hài lòng chung, còn phần nhận xét cho biết lý do phía sau mức điểm đó. Khi kết hợp hai loại dữ liệu, đối tượng phân tích được mô tả rõ hơn so với việc dựa riêng vào dữ liệu số.

2.1.2. Đặc điểm của dữ liệu văn bản

Dữ liệu văn bản có tính không đồng nhất cao. Cùng một nội dung, người viết có nhiều cách diễn đạt khác nhau. Sự khác biệt nằm ở từ ngữ, độ dài câu, cách nhấn mạnh và ngôn ngữ được dùng. Đặc điểm này làm cho các phương pháp dựa trên từ khóa đơn lẻ dễ bỏ sót những nội dung có cùng ý nghĩa nhưng khác cách viết.

Ngữ cảnh ảnh hưởng trực tiếp đến nghĩa của văn bản. Một từ riêng lẻ chưa đủ để xác định thái độ hoặc nội dung của cả câu. Quan hệ giữa các từ và vị trí của chúng trong câu quyết định nhiều đến ngữ nghĩa và cần các phương pháp biểu diễn hiện đại thường hướng đến việc mã hóa cả câu hoặc đoạn văn thành vector ngữ nghĩa.

Nguồn văn bản do người dùng tạo ra cũng thường chứa nhiễu. Nhiễu gồm lỗi chính tả, ký tự đặc biệt, đường dẫn, khoảng trắng thừa, từ viết tắt và câu trả lời quá ngắn. Những yếu tố này làm giảm chất lượng đầu vào của mô hình. Với dữ liệu có nhiều ngôn ngữ, sự khác biệt về hệ chữ viết và cấu trúc câu còn làm quá trình biểu diễn văn bản khó hơn.

2.2. Xử lý ngôn ngữ tự nhiên

2.2.1. Khái quát về xử lý ngôn ngữ tự nhiên

Xử lý ngôn ngữ tự nhiên là nhánh kỹ thuật nghiên cứu cách máy tính tiếp nhận và xử lý ngôn ngữ của con người. Mục tiêu của quá trình là biến văn bản thô thành dạng dữ liệu có cấu trúc hơn. Dữ liệu sau xử lý thường gồm văn bản đã chuẩn hóa, nhãn ngôn ngữ, nhãn cảm xúc, đặc trưng từ vựng hoặc vector ngữ nghĩa.

Một hệ thống xử lý văn bản không xử lý câu chữ như con người đọc hiểu. Hệ thống chuyển nội dung thành dạng biểu diễn phù hợp với phép tính. Khi văn bản đã được biểu diễn bằng số, mô hình đo được mức độ giống nhau giữa các nội dung, nhận diện sắc thái hoặc phân nhóm các mẫu dữ liệu.

Trong phân tích phản hồi người dùng, xử lý ngôn ngữ tự nhiên là bước trung gian giữa văn bản thô và mô hình học máy. Văn bản ban đầu chứa nhiều cách viết khác nhau. Sau xử lý, mỗi văn bản có dạng biểu diễn thống nhất hơn để tiếp tục đưa vào các bước phân tích.

2.2.2. Các bước xử lý văn bản cơ bản

Quy trình xử lý văn bản gồm làm sạch, chuẩn hóa và biểu diễn số. Làm sạch loại bỏ các thành phần gây nhiễu như ký tự điều khiển, đường dẫn, email, khoảng trắng thừa hoặc chuỗi không mang thông tin phân tích và giữ lại phần nội dung có giá trị và giảm sai lệch cho các bước phía sau.

Chuẩn hóa giúp dữ liệu văn bản nhất quán. Một số thao tác thường gặp gồm chuẩn hóa mã hóa ký tự, thống nhất khoảng trắng, xử lý chữ hoa, chữ thường và giữ lại các ký tự có ý nghĩa theo ngôn ngữ. Với dữ liệu đa ngôn ngữ, bước chuẩn hóa phải thận trọng. Việc xóa dấu hoặc loại bỏ ký tự Unicode có thể làm sai nội dung gốc.

Sau khi làm sạch và chuẩn hóa, văn bản được chuyển thành dạng số. Các phương pháp truyền thống biểu diễn văn bản bằng tần suất từ. Các phương pháp hiện đại mã hóa câu hoặc đoạn văn thành vector ngữ nghĩa. Dạng biểu diễn này tạo cơ sở cho việc đo tương đồng, gán nhãn, nhận diện cảm xúc và phân cụm.

2.2.3. Đặc điểm của dữ liệu đa ngôn ngữ

Dữ liệu đa ngôn ngữ gồm các văn bản thuộc nhiều ngôn ngữ trong cùng một tập dữ liệu. Mỗi ngôn ngữ có hệ chữ viết, từ vựng, cấu trúc câu và cách biểu đạt riêng. Sự khác biệt này ảnh hưởng trực tiếp đến cách mô hình biểu diễn nội dung.

Trong không gian vector, hai văn bản có cùng ý nghĩa nên nằm gần nhau. Với dữ liệu đa ngôn ngữ, yêu cầu này khó hơn vì mô hình phải học quan hệ giữa các ngôn ngữ khác nhau. Khi biểu diễn không tốt, hai câu gần nhau về nghĩa nhưng khác ngôn ngữ sẽ bị đặt xa nhau. Khoảng cách sai lệch này làm giảm chất lượng phân tích ngữ nghĩa.

2.3. Phân tích cảm xúc

Phân tích cảm xúc, còn gọi là khai thác quan điểm, là kỹ thuật xử lý văn bản nhằm xác định thái độ hoặc cảm nhận được thể hiện trong nội dung ngôn ngữ. Trong dữ liệu đánh giá, thái độ của người viết thường được chia thành ba nhóm chính: tích cực, trung lập và tiêu cực. Nhóm tích cực biểu thị sự hài lòng hoặc đánh giá tốt. Nhóm tiêu cực biểu thị sự không hài lòng hoặc phàn nàn. Nhóm trung lập biểu thị nội dung không nghiêng rõ về khen hoặc chê.

Về bản chất, phân tích cảm xúc là bài toán phân loại văn bản. Văn bản đầu vào được xử lý để rút ra đặc trưng, sau đó mô hình hoặc quy tắc gán văn bản vào nhóm cảm xúc phù hợp. Cách tiếp cận dựa trên từ điển dùng tập từ mang sắc thái tích cực hoặc tiêu cực. Cách tiếp cận dựa trên học máy học mối quan hệ giữa văn bản và nhãn cảm xúc từ dữ liệu đã gán nhãn.

Cảm xúc trong văn bản không nằm hoàn toàn ở một vài từ đơn lẻ. Một câu có từ tích cực vẫn mang ý phàn nàn nếu xuất hiện trong cấu trúc phủ định. Một câu ngắn vẫn thể hiện sự hài lòng khi sắc thái của câu rõ. Phân tích cảm xúc cần xét nội dung và ngữ cảnh câu, thay vì tách rời từng từ.

2.4. Phân tích cảm xúc theo khía cạnh

2.4.1. Khái niệm aspect

Aspect là khía cạnh cụ thể được nhắc đến trong một văn bản đánh giá. Một phản hồi thường đề cập đến nhiều phần khác nhau của đối tượng được đánh giá. Mỗi phần mang một nội dung riêng và đôi khi đi kèm một sắc thái cảm xúc riêng, aspect giúp chia văn bản thành các đơn vị nhỏ hơn để phân tích chi tiết hơn.

Một văn bản có cảm xúc chung tích cực vẫn chứa phàn nàn về một khía cạnh cụ thể. Nếu gán một nhãn cảm xúc cho toàn văn bản, phần khác biệt giữa các khía cạnh dễ bị mất. Phân tích theo aspect giúp giữ lại thông tin chi tiết này.

Trong dữ liệu đánh giá, aspect thường gắn với các phần được người dùng nhắc đến nhiều. Mỗi aspect có thể được xem xét theo số lần xuất hiện, số lần được khen và số lần bị chê. Khi được tổng hợp trên nhiều phản hồi, các thông tin này tạo thành đặc trưng định lượng.

2.4.2. Nguyên lý phân tích cảm xúc theo khía cạnh

Phân tích cảm xúc theo khía cạnh xử lý hai nhiệm vụ chính. Nhiệm vụ thứ nhất là nhận diện khía cạnh được nhắc đến trong văn bản. Nhiệm vụ thứ hai là xác định cảm xúc gắn với khía cạnh đó. Kết quả thường được biểu diễn bằng một cặp gồm aspect và sentiment. Nếu một văn bản nhắc đến nhiều khía cạnh, mô hình tạo ra nhiều cặp kết quả. Ví dụ tổng quát: ($A1$, *positive*), ($A2$, *negative*)

Trong đó, $A1$ và $A2$ là hai khía cạnh khác nhau. Cách biểu diễn giúp phép tách cảm xúc tổng thể thành các đơn vị nhỏ hơn. Nhờ đó, dữ liệu đánh giá được mô tả theo từng phần thay vì bị nén thành một nhãn chung.

2.5. Embedding văn bản

2.5.1. Khái niệm embedding văn bản

Embedding văn bản là phương pháp biểu diễn văn bản thành vector số trong không gian nhiều chiều. Mỗi từ, câu hoặc đoạn văn được mã hóa thành một điểm trong

không gian. Các văn bản gần nhau về nghĩa thường có vector gần nhau hơn so với các văn bản khác nghĩa.

Nếu d là một văn bản và E là mô hình embedding, vector biểu diễn của d được biểu diễn:

$$v_d = E(d), v_d \in R^k$$

Trong đó, v_d là vector của văn bản d, k là số chiều của vector. Dạng biểu diễn này giúp mô hình tính được khoảng cách và độ tương đồng giữa các văn bản.

Thước đo dùng là cosine similarity:

$$\cos(v_i, v_j) = \frac{v_i \cdot v_j}{\|v_i\| \|v_j\|}$$

Trong đó, v_i và v_j là hai vector văn bản. Giá trị cosine càng lớn, hai vector càng gần nhau về hướng sẽ phản ánh sự gần nhau về ngữ nghĩa.

2.5.2. Embedding đa ngôn ngữ

Embedding đa ngôn ngữ mở rộng biểu diễn vector cho dữ liệu có nhiều ngôn ngữ. Mục tiêu của kỹ thuật này là đưa các văn bản có ý nghĩa tương đồng vào cùng một không gian biểu diễn, dù chúng được viết bằng các ngôn ngữ khác nhau.

Khi mô hình biểu diễn tốt, một câu tiếng Việt và một câu tiếng Anh cùng nghĩa có vector gần nhau. Cách biểu diễn này giúp việc đo tương đồng và phân nhóm nội dung không bị tách rời theo ngôn ngữ. Với dữ liệu trực tuyến, embedding đa ngôn ngữ phù hợp hơn so với cách xử lý riêng từng ngôn ngữ.

2.5.3. Mô hình Multilingual-E5-Large

Multilingual-E5-Large là mô hình embedding đa ngôn ngữ do Microsoft phát triển, dựa trên kiến trúc XLM-RoBERTa-Large. Mô hình có khoảng 560 triệu tham số, tạo vector 1024 chiều cho mỗi văn bản và hỗ trợ hơn 100 ngôn ngữ. Với giới hạn ngữ

cảnh 512 tokens, mô hình phù hợp với câu đánh giá, đoạn nhận xét ngắn hoặc văn bản đã được tách nhỏ.

Mô hình học biểu diễn ngữ nghĩa từ các cặp văn bản có quan hệ với nhau, truy vấn và đoạn văn liên quan. Giúp các văn bản gần nhau về nghĩa có vector gần nhau trong không gian biểu diễn, thay vì phụ thuộc vào việc trùng từ khóa. Khi áp dụng cho dữ liệu đánh giá đa ngôn ngữ, Multilingual-E5-Large chuyển nội dung nhận xét thành vector số để phục vụ các bước đo độ tương đồng, phân nhóm nội dung và xây dựng đặc trưng cho mô hình phân tích.

2.6. Đặc trưng dữ liệu

2.6.1. Khái niệm đặc trưng dữ liệu

Đặc trưng dữ liệu là các biến dùng để mô tả một đối tượng trong mô hình học máy. Đặc trưng được lấy trực tiếp từ dữ liệu gốc hoặc được tính toán từ nhiều bản ghi liên quan. Mỗi đối tượng sau khi được mô tả bằng các đặc trưng sẽ có một vector đại diện.

Một đối tượng có p đặc trưng, vector đặc trưng được biểu diễn:

$$x = [x_1, x_2 \ldots, x_p]$$

Trong đó, x là vector đại diện cho đối tượng, x_1 đến x_p là các đặc trưng. Vector trên là dạng dữ liệu mà mô hình phân tích dùng để đo khoảng cách hoặc độ tương đồng giữa các đối tượng.

Chất lượng đặc trưng ảnh hưởng trực tiếp đến chất lượng mô hình. Đặc trưng phù hợp giúp các đối tượng gần nhau về bản chất nằm gần nhau trong không gian dữ liệu. Đặc trưng nhiễu làm khoảng cách bị sai lệch và khiến kết quả khó diễn giải.

2.6.2. Kết hợp dữ liệu số và dữ liệu văn bản

Các bộ dữ liệu thực tế gồm cả dữ liệu số và dữ liệu văn bản. Dữ liệu số cung cấp thông tin định lượng. Dữ liệu văn bản cung cấp bối cảnh, sắc thái và nội dung giải thích cho các giá trị đó. Khi kết hợp hai nguồn này, vector đặc trưng mô tả đối tượng đầy đủ hơn.

Đặc trưng tổng hợp thường được tạo bằng các phép tính như trung bình, tỷ lệ, tần suất hoặc độ đa dạng. Với dữ liệu văn bản, nhãn cảm xúc, aspect và embedding được chuyển thành các biến số trước khi đưa vào mô hình. Quá trình này làm cho thông tin ngôn ngữ trở thành một phần của vector đặc trưng.

2.6.3. RobustScaler

RobustScaler là phương pháp chuẩn hóa đặc trưng dựa trên trung vị và khoảng tứ phân vị. Khác với chuẩn hóa z-score dùng trung bình và độ lệch chuẩn, RobustScaler ít bị ảnh hưởng bởi các giá trị ngoại lệ. Điều này phù hợp với dữ liệu có phân bố lệch hoặc có một số quan sát mang giá trị lớn bất thường.

Với một đặc trưng x, RobustScaler được tính theo công thức:

$$x_{scaled} = \frac{x - median(x)}{IQR(x)}$$

Trong đó, $median(x)$ là trung vị của đặc trưng x. $IQR(x)$ là khoảng tứ phân vị, được tính bằng hiệu giữa phân vị thứ ba và phân vị thứ nhất:

$$IQR(x) = Q_3(x) - Q_1(x)$$

Sau chuẩn hóa, các đặc trưng được đưa về thang đo ổn định hơn trước khi tính khoảng cách hoặc đưa vào thuật toán phân cụm. Cách chuẩn hóa này phù hợp khi bộ dữ liệu có sự chênh lệch lớn giữa các biến, chẳng hạn số lượng review, điểm đánh giá hoặc các tỷ lệ được tổng hợp từ dữ liệu văn bản.

2.7. Giảm chiều dữ liệu bằng PCA

2.7.1. Khái niệm giảm chiều dữ liệu

Giảm chiều dữ liệu là quá trình chuyển dữ liệu từ không gian nhiều chiều sang không gian có số chiều thấp hơn. Mục tiêu là giữ lại phần thông tin chính, đồng thời làm dữ liệu gọn hơn. Kỹ thuật này thường được dùng khi bộ đặc trưng có nhiều biến, nhiều biến tương quan hoặc dữ liệu chứa nhiễu.

Khi số lượng đặc trưng lớn, việc tính toán và trực quan hóa trở nên khó hơn. Một số biến mang thông tin trùng lặp, làm không gian dữ liệu rộng hơn nhưng không bổ sung nhiều giá trị phân tích. Giảm chiều giúp tạo ra biểu diễn gọn hơn, giảm ảnh hưởng của biến thừa và hỗ trợ quan sát cấu trúc dữ liệu.

2.7.2. Nguyên lý của PCA

PCA (Principal Component Analysis) là phương pháp giảm chiều tuyến tính. Phương pháp này tạo ra các thành phần chính từ tổ hợp tuyến tính của các biến ban đầu. Thành phần chính thứ nhất giữ lượng phương sai lớn nhất. Các thành phần tiếp theo giữ phần phương sai còn lại và trực giao với các thành phần trước đó.

Một thành phần chính được viết dưới dạng:

$$Z_k = a_1X_1 + a_2X_2 + \cdots + a_pX_p$$

Trong đó, Z_k là thành phần chính thứ k, X_1 đến X_p là các biến ban đầu, a_1 đến a_p là hệ số tuyến tính. Các hệ số được xác định sao cho phương sai của thành phần chính đạt giá trị cao theo thứ tự giảm dần.

2.7.3. Tỷ lệ phương sai giữ lại

Tỷ lệ phương sai giữ lại cho biết lượng thông tin còn lại sau khi giảm chiều bằng PCA. Khi chọn m thành phần đầu tiên, tỷ lệ này được tính:

$$EVR_m = \frac{\lambda_1 + \lambda_2 + \cdots + \lambda_m}{\lambda_1 + \lambda_2 + \cdots + \lambda_p}$$

Trong đó, λ_i là trị riêng ứng với thành phần chính thứ i, m là số thành phần được chọn, p là tổng số thành phần. EVR_m càng cao, dữ liệu sau giảm chiều giữ lại càng nhiều biến thiên từ dữ liệu ban đầu.

2.8. Các thuật toán phân cụm

2.8.1. KMeans

KMeans là thuật toán phân cụm dựa trên khoảng cách đến tâm cụm. Thuật toán chia dữ liệu thành K cụm. Mỗi điểm được gán vào cụm có tâm gần nhất, sau đó tâm cụm được cập nhật bằng trung bình của các điểm trong cụm. Quá trình này lặp lại đến khi nhãn cụm ổn định hoặc đạt giới hạn lặp.

Hàm mục tiêu của KMeans là tối thiểu hóa tổng bình phương khoảng cách trong cụm:

$$J = \sum_{i=1}^{K} \sum_{x \in C_i} \|x - \mu_i\|^2$$

Trong đó, C_i là cụm thứ i, $\mu_i$là tâm cụm thứ i, x là một điểm dữ liệu. Giá trị J càng nhỏ, các điểm trong cụm càng gần tâm cụm.

2.8.2. Agglomerative Clustering

Agglomerative Clustering là thuật toán phân cụm phân cấp theo hướng gộp dần. Ban đầu, mỗi điểm dữ liệu được xem là một cụm riêng. Thuật toán lần lượt gộp hai cụm gần nhau nhất cho đến khi đạt số cụm mong muốn.

Khoảng cách giữa các cụm được xác định bằng tiêu chí liên kết. Một số tiêu chí thường gặp là single linkage, complete linkage, average linkage và ward linkage. Với ward linkage, hai cụm được gộp sao cho mức tăng phương sai trong cụm nhỏ nhất. Kết quả của thuật toán thường được biểu diễn bằng cây phân cấp để quan sát quá trình gộp cụm.

2.8.3. Gaussian Mixture Model

Gaussian Mixture Model, giả định dữ liệu được sinh ra từ hỗn hợp nhiều phân phối Gaussian. Mỗi cụm tương ứng với một phân phối thành phần. Khác với KMeans, GMM gán điểm dữ liệu vào cụm theo xác suất.

Hàm mật độ của GMM có dạng:

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x|\mu_k, \Sigma_k)$$

Trong đó, π_k là trọng số của thành phần thứ k, μ_k là vector trung bình, Σ_k là ma trận hiệp phương sai, $\mathcal{N}(x|\mu_k, \Sigma_k)$ là mật độ Gaussian. Và Tổng các trọng số π_k bằng 1. Cách mô hình hóa này cho phép cụm có độ phân tán và hình dạng khác nhau.

2.8.4. DBSCAN

DBSCAN là thuật toán phân cụm dựa trên mật độ. Thuật toán xác định các vùng có mật độ điểm cao và gom các điểm trong vùng đó thành cụm. Các điểm nằm tách biệt khỏi vùng đủ mật độ được xem là nhiễu.

DBSCAN dựa trên hai tham số chính: eps và $min_samples$. eps là bán kính lân cận quanh một điểm. $min_samples$ là số điểm tối thiểu trong vùng lân cận để điểm đó trở thành điểm lõi. Một điểm x là điểm lõi nếu:

$$|N_\varepsilon(x)| \geq min_samples$$

Trong đó, $N_\varepsilon(x)$ là tập các điểm nằm trong bán kính eps quanh x. DBSCAN không yêu cầu chọn trước số cụm, nhưng kết quả phụ thuộc nhiều vào eps và $min_samples$.

2.9. Các chỉ số đánh giá phân cụm

2.9.1. Silhouette Score

Silhouette Score đo mức phù hợp của một điểm dữ liệu với cụm hiện tại so với cụm gần nhất khác. Chỉ số này kết hợp độ gần với các điểm cùng cụm và độ xa với cụm lân cận.

Công thức Silhouette của điểm i:

$$s(i) = \frac{b(i) - a(i)}{max(a(i), b(i))}$$

Trong đó, $a(i)$ là khoảng cách trung bình từ điểm i đến các điểm cùng cụm, $b(i)$ là khoảng cách trung bình nhỏ nhất từ điểm i đến các điểm thuộc cụm khác. Giá trị gần 1 cho thấy điểm phù hợp với cụm hiện tại. Giá trị gần 0 cho thấy điểm nằm gần ranh giới. Giá trị âm cho thấy điểm có khả năng bị gán sai cụm.

2.9.2. Davies-Bouldin Index

Davies-Bouldin Index đánh giá độ chặt trong cụm và độ tách giữa các cụm. Chỉ số này so sánh độ phân tán của hai cụm với khoảng cách giữa tâm của chúng.

Công thức tổng quát:

$$DBI = \frac{1}{K}\sum_{i=1}^{K} \max_{j \neq i}\left(\frac{S_i + S_j}{M_{ij}}\right)$$

Trong đó, $S_i$và S_j là độ phân tán của cụm i và cụm i, M_{ij} là khoảng cách giữa hai tâm cụm, k là số cụm. Giá trị DBI càng thấp, các cụm càng gọn và tách biệt hơn

2.9.3. Calinski-Harabasz Index

Calinski-Harabasz Index đo tỷ lệ giữa độ phân tán giữa cụm và độ phân tán trong cụm. Chỉ số này cao khi các cụm cách xa nhau và các điểm trong cùng cụm gần nhau.

Công thức tổng quát:

$$CH = \frac{\frac{Tr(B_K)}{K-1}}{\frac{Tr(W_K)}{n-K}}$$

Trong đó, B_k là ma trận phân tán giữa các cụm, W_k là ma trận phân tán trong cụm, K là số cụm, n là số điểm dữ liệu, Tr là tổng các phần tử trên đường chéo chính của ma trận. Giá trị CH càng cao thường cho thấy cấu trúc cụm rõ hơn.

2.9.4. Inertia và Elbow Method

Inertia là tổng bình phương khoảng cách từ mỗi điểm dữ liệu đến tâm cụm gần nhất. Chỉ số này thường dùng trong KMeans để đo độ chặt của các cụm.

$$Inertia = \sum_{i=1}^{K} \sum_{x \in C_i} \|x - \mu_i\|^2$$

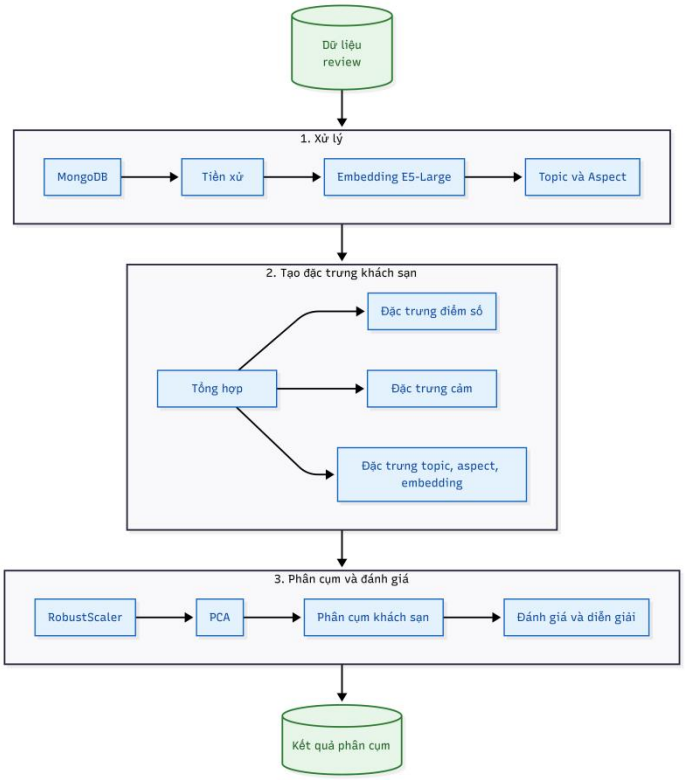
Khi số cụm K tăng, Inertia thường giảm vì mỗi cụm chứa ít điểm hơn. Elbow Method quan sát đồ thị Inertia theo K để tìm điểm gãy. Sau điểm này, việc tăng thêm số cụm không làm Inertia giảm nhiều như trước. Đây là cơ sở tham khảo khi chọn số cụm cho KMeans.

CHƯƠNG 3. PHƯƠNG PHÁP THỰC NGHIỆM

3.1. Tổng quan quy trình thực hiện

Quy trình thực nghiệm của đề tài gồm các bước chính: tổ chức dữ liệu vào MongoDB, tiền xử lý review, tạo embedding bằng Multilingual-E5-Large, gán topic và aspect, xây dựng đặc trưng cấp khách sạn, chuẩn hóa bằng RobustScaler, giảm chiều bằng PCA và phân cụm.. Đối tượng phân cụm cuối cùng là khách sạn, không phải từng review riêng lẻ.

Dữ liệu review sau xử lý được dùng để rút ra sentiment, topic, aspect và embedding. Các thông tin này được tổng hợp cùng điểm đánh giá, tiêu chí dịch vụ và thông tin khách hàng để tạo bộ đặc trưng cấp khách sạn. Bộ đặc trưng sau đó được đưa vào các thuật toán KMeans, Agglomerative Clustering, Gaussian Mixture Model và DBSCAN. Kết quả được đánh giá bằng Silhouette Score, Davies-Bouldin Index, Calinski-Harabasz Index và Inertia.



Hình 3.1. Quy trình thực nghiệm của đề tài

3.2. Dữ liệu đầu vào

Dữ liệu đầu vào của đề tài được thu thập từ Booking.com, gồm thông tin khách sạn và review của khách hàng. Sau khi đưa vào MongoDB, bộ dữ liệu gồm 63 tỉnh/thành, 2.325 khách sạn và 18.779 review. Toàn bộ 18.779 review đều có nội dung văn bản, không ghi nhận review rỗng trong tập dữ liệu đã import. Các review này được dùng làm nguồn đầu vào cho bước tiền xử lý, gán sentiment, tạo embedding, gán topic và aspect.

Mỗi bản ghi khách sạn chứa các thông tin cơ bản như tên khách sạn, địa chỉ, mô tả, điểm đánh giá tổng quan, tổng số lượt đánh giá và các tiêu chí đánh giá chi tiết. Phần review gồm thông tin người đánh giá, quốc gia, ngày đánh giá, điểm số, loại phòng, thời gian lưu trú, nhóm khách, nhận xét tích cực và nhận xét tiêu cực. Các trường này là cơ sở để xây dựng đặc trưng cấp khách sạn ở các bước sau.

Nội dung	Số lượng
Số tỉnh/thành	63
Số khách sạn	2.325
Số review	18.779
Số review có nội dung văn bản	18.779
Số reviewkhông có nội dung văn bản	0
Số review dùng để embedding	18.779

Bảng 3.1. Thống kê dữ liệu đầu vào

3.3. Tiền xử lý dữ liệu review

TiềnTiền xử lý review nhằm tạo dữ liệu văn bản sạch hơn cho bước embedding, gán aspect và xây dựng đặc trưng. Quy trình chỉ xử lý các review có nội dung, đồng thời giữ nguyên dấu, Unicode và cấu trúc ngôn ngữ gốc để phù hợp với dữ liệu đa ngôn ngữ.

Hai phần nhận xét tích cực và tiêu cực được làm sạch riêng. Các giá trị rỗng như “nan”, “none”, “null” được chuyển về thiếu. Văn bản được giải mã HTML, chuẩn hóa

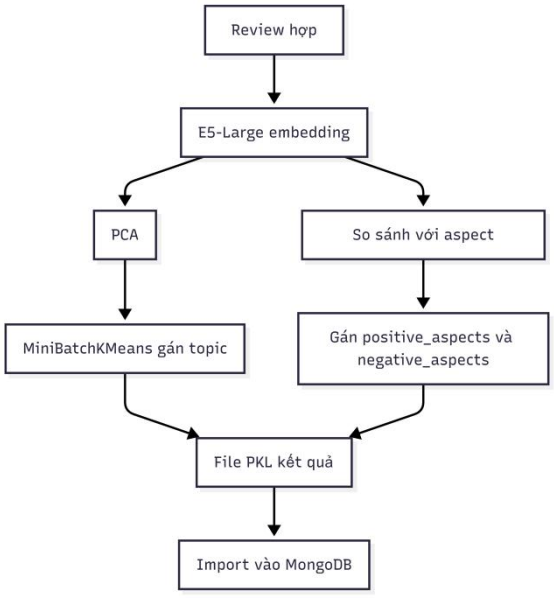
Unicode, loại bỏ URL, email, ký tự điều khiển và khoảng trắng thừa. Nội dung sau xử lý được ghép thành embedding_text bằng hai nhãn POSITIVE và NEGATIVE, phân tách bằng ký hiệu [SEP].

Các review quá ngắn hoặc ít thông tin bị loại khỏi bước tạo embedding. Review không đạt điều kiện nếu dưới 20 ký tự, dưới 4 từ hoặc thuộc nhóm câu chung chung như "ok", "good", "nice", "tốt", "không có". Các review hợp lệ được đánh dấu bằng is_valid_for_embedding và is_valid_for_aspect để đưa sang bước tiếp theo.

3.4. Tạo embedding cho review

Các review hợp lệ được mã hóa bằng Multilingual-E5-Large để tạo vector ngữ nghĩa 1024 chiều. Bước này được thực hiện trên Google Colab nhằm tận dụng GPU. Kết quả embedding sau đó được nhập lại vào MongoDB để dùng cho các bước gán topic, gán aspect và xây dựng đặc trưng.

Embedding không được dùng để phân cụm trực tiếp từng review trong kết quả cuối. Vector review chỉ đóng vai trò trung gian để rút ra thông tin ngữ nghĩa, sau đó các thông tin này được tổng hợp ở cấp khách sạn.



Hình 3.2. Quy trình tạo embedding, topic và aspect

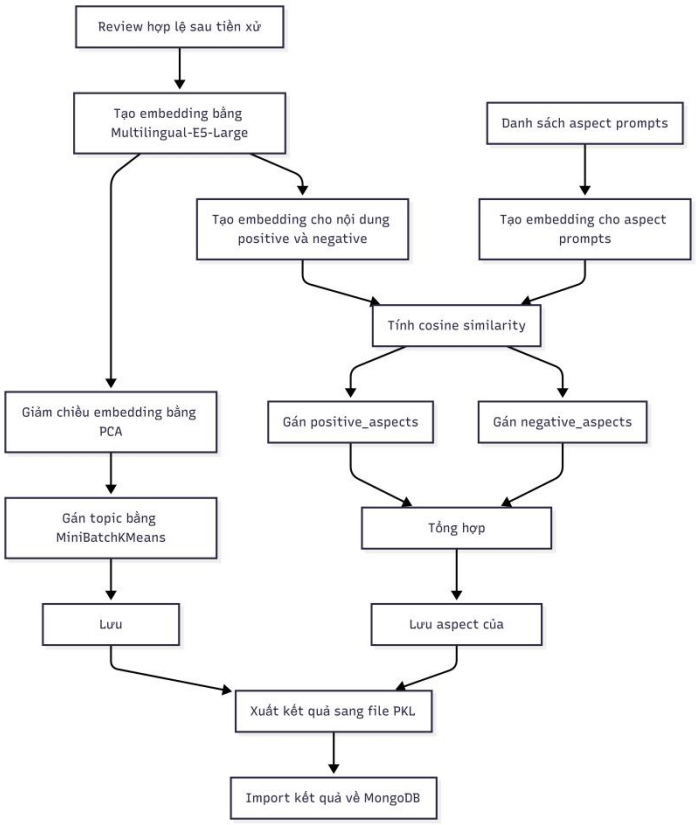
3.5. Gán topic và aspect

Topic được gán để nhận diện nhóm nội dung chính của review. Các vector review được dùng trong bước phân cụm topic, sau đó mỗi review nhận một nhãn topic. Thông tin này được tổng hợp thành tỷ lệ topic theo từng khách sạn.

Aspect được gán để xác định khía cạnh khách hàng nhắc đến trong review. Các aspect gồm các nhóm liên quan đến trải nghiệm lưu trú như phòng, vệ sinh, vị trí, nhân viên, bữa sáng, wifi, giá cả và tiện nghi. Review không đủ rõ để xác định aspect được xử lý riêng nhằm hạn chế gán sai.

STT	Aspect	Ý nghĩa
1	room	Phản hồi liên quan đến phòng, không gian phòng, giường, nội thất hoặc chất lượng phòng
2	cleanliness	Phản hồi liên quan đến vệ sinh, độ sạch của phòng, nhà vệ sinh hoặc khu vực lưu trú
3	service	Phản hồi liên quan đến nhân viên, thái độ phục vụ và hỗ trợ khách hàng
4	location	Phản hồi liên quan đến vị trí, khoảng cách di chuyển và sự thuận tiện xung quanh
5	price	Phản hồi liên quan đến giá cả, mức độ đáng tiền và chi phí lưu trú
6	food	Phản hồi liên quan đến bữa sáng, đồ ăn hoặc dịch vụ ăn uống
7	facilities	Phản hồi liên quan đến tiện nghi, trang thiết bị và cơ sở vật chất
8	wifi	Phản hồi liên quan đến kết nối Internet hoặc chất lượng Wi-Fi
9	noise	Phản hồi liên quan đến tiếng ồn, cách âm hoặc sự yên tĩnh
10	checkin	Phản hồi liên quan đến nhận phòng, trả phòng và thủ tục tại khách sạn

Bảng 3.2. Danh sách aspect được xét



Hình 3.3. Quy trình gán topic và aspect

3.6. Xây dựng đặc trưng cấp khách sạn

Đặc trưng cấp khách sạn được tạo bằng cách tổng hợp các review thuộc cùng một khách sạn. Bộ đặc trưng gồm nhóm rating và sentiment, nhóm quốc gia khách hàng, nhóm tiêu chí dịch vụ, nhóm topic và nhóm aspect. Các đặc trưng này mô tả khách sạn theo cả dữ liệu số và nội dung review.

Nhóm rating và sentiment phản ánh điểm đánh giá, số lượng review và tỷ lệ cảm xúc. Nhóm quốc gia thể hiện mức độ đa dạng của khách hàng. Nhóm tiêu chí dịch vụ lấy từ điểm đánh giá chi tiết. Nhóm topic và aspect phản ánh nội dung thường xuất hiện trong review và các khía cạnh được khen hoặc chê.

STT	Nhóm đặc trưng	Các Đặc trưng chính	Ý nghĩa
1	Rating và sentiment	num_reviews, avg_review_rating, std_review_rating, min_review_rating, max_review_rating, positive_ratio, neutral_ratio, negative_ratio, avg_sentiment_score	Mô tả điểm đánh giá, số lượng review và xu hướng cảm xúc của khách hàng
2	Độ dài văn bản	avg_char_count, avg_word_count, max_word_count, short_review_ratio, valid_embedding_ratio	Mô tả độ dài review và tỷ lệ review đủ điều kiện xử lý văn bản
3	Quốc gia khách hàng	num_customer_countries, top_country_ratio, country_diversity	Mô tả mức độ đa dạng quốc gia của khách đánh giá
4	Nhóm khách	couple_ratio, family_ratio, solo_ratio, group_ratio, other_ratio, unknown_ratio	Mô tả cơ cấu nhóm khách lưu trú theo review
5	Topic	topic_0_ratio đến topic_11_ratio	Mô tả tỷ lệ các nhóm nội dung chính xuất hiện trong review
6	Aspect	room, cleanliness, service, location, price, food, facilities, wifi, noise, checkin theo positive_ratio, negative_ratio và mention_ratio	Mô tả các khía cạnh được khen, chê hoặc được nhắc đến trong review
7	Tiêu chí dịch vụ	service_staff, amenities, cleanliness, comfort, value_for_money, location, free_wifi	Mô tả các điểm đánh giá chi tiết có sẵn trong dữ liệu khách sạn

Bảng 3.3. Nhóm đặc trưng cấp khách sạn

3.7. Chuẩn bị đặc trưng khách sạn cho phân cụm

Sau khi xây dựng bộ đặc trưng cấp khách sạn, dữ liệu được chuẩn bị lại trước khi đưa vào mô hình phân cụm. Đối tượng xử lý là khách sạn, không còn là review. Điều kiện lọc được áp dụng là mỗi khách sạn phải có từ 3 review trở lên. Các khách sạn có số review nhỏ hơn 3 bị loại khỏi tập phân cụm vì lượng phản hồi quá ít, khó đại diện ổn định cho đặc điểm của khách sạn.

Các nhóm đặc trưng được giữ lại gồm rating, sentiment, tiêu chí đánh giá dịch vụ, aspect và độ đa dạng quốc gia của khách hàng. Các nhóm topic, độ dài review, nhóm khách và metadata không được đưa vào mô hình cuối. Cấu hình này hỗ trợ dữ liệu phân cụm tập trung vào các đặc trưng phản ánh chất lượng khách sạn và cảm xúc của khách hàng.

Sau khi chọn đặc trưng, bộ dữ liệu còn 54 đặc trưng đầu vào. Các đặc trưng này được chuẩn hóa bằng RobustScaler để giảm ảnh hưởng của các giá trị lớn bất thường. PCA được dùng để giảm chiều dữ liệu từ 54 đặc trưng xuống 8 thành phần chính. Với 8 thành phần PCA, tỷ lệ phương sai giữ lại đạt 0,7405, tương đương khoảng 74,05%. Mức này giúp rút gọn không gian đặc trưng nhưng vẫn giữ phần biến thiên chính của dữ liệu để phục vụ phân cụm.

Nội Dung	Cấu hình sử dụng
Đối tượng phân cụm	Khách sạn
Điều kiện lọc	Num_reviews >= 3
Số đặc trưng trước giảm chiều PCA	54
Nhóm đặc trưng được sử dụng	rating, sentiment, evaluation categories, aspect, country diversity
Phương pháp chuẩn hóa	RobustScaler
Số thành phần PCA	8
Tỷ lệ phương sai giữ lại	0,7405

Bảng 3.4. Cấu hình dữ liệu đầu vào cho phân cụm

3.8. Phân cụm

Nghiên cứu thử nghiệm bốn thuật toán phân cụm gồm KMeans, Agglomerative Clustering, Gaussian Mixture Model và DBSCAN. Với KMeans, Agglomerative Clustering và Gaussian Mixture Model, số cụm được thử trong khoảng từ 2 đến 10. Với DBSCAN, mô hình được thử với nhiều giá trị eps và min_samples = 5 để kiểm tra khả năng gom nhóm theo mật độ.

Mô hình cuối được chọn là KMeans với K = 3. Lựa chọn này dựa trên kết quả so sánh giữa các cấu hình phân cụm. KMeans với K = 3 có Silhouette Score đạt 0,3701, Davies-Bouldin Index đạt 1,2159 và Calinski-Harabasz Index đạt 791,1883. So với KMeans K = 4, K = 3 có Silhouette Score thấp hơn rất ít, nhưng Davies-Bouldin Index thấp hơn và Calinski-Harabasz Index cao hơn. Điều này cho thấy cấu hình K = 3 cân bằng hơn giữa độ chặt trong cụm và độ tách biệt giữa các cụm.

Nội dung	Cấu hình sử dụng
Thuật toán thử nghiệm	KMeans, Agglomerative Clustering, GMM, DBSCAN
K thử nghiệm	2 đến 10
Tham số DBSCAN	eps thay đổi, min_samples = 5
Chỉ số đánh giá	Silhouette Score, Davies-Bouldin Index, Calinski-Harabasz Index
Chỉ số đánh giá riêng KMeans	Inertia
Mô hình cuối cùng	KMeans, K = 3
Silhouette Score của mô hình cuối	0,3701
Davies-Bouldin Index của mô hình cuối	1,2159
Calinski-Harabasz Index của mô hình cuối	791,1883

Bảng 3.5. Các thuật toán và chỉ số đánh giá được dùng

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

4.1. Môi trường và cấu hình thực nghiệm

4.1.1. Môi trường thực nghiệm

Thực nghiệm được thực hiện trên môi trường kết hợp giữa máy tính cá nhân và Google Colab. Máy tính cá nhân được dùng để lưu trữ dữ liệu, xử lý MongoDB, xây dựng đặc trưng cấp khách sạn và chạy các thuật toán phân cụm. Google Colab GPU được dùng cho bước tạo embedding bằng mô hình Multilingual-E5-Large, vì bước này cần tài nguyên tính toán lớn hơn.

Dữ liệu được lưu trong MongoDB local. Các bước xử lý chính được viết bằng Python và sử dụng các thư viện phục vụ xử lý dữ liệu, học máy, trực quan hóa và tạo embedding.

Thành phần	Thông tin
Ngôn ngữ lập trình	Python 3.x
Hệ điều hành local	Windows
Cơ sở dữ liệu	MongoDB
Môi trường embedding	Google Colab GPU
Thư viện chính	pandas, numpy, scikit-learn, pymongo, sentence-transformers, matplotlib
Mô hình embedding	intfloat/multilingual-e5-large
Thuật toán phân cụm	KMeans, Agglomerative, GMM, DBSCAN

Bảng 4.1. Môi trường thực nghiệm

4.1.2. Cấu hình thực nghiệm chính

Cấu hình thực nghiệm được xây dựng theo mục tiêu phân cụm khách sạn dựa trên đặc tính và cảm xúc của khách hàng. Sau khi xây dựng đặc trưng cấp khách sạn, dữ liệu được chuẩn hóa bằng RobustScaler, giảm chiều bằng PCA và đưa vào mô hình phân cụm.

Nội dung	Giá trị
Điều kiện lọc khách sạn	num_reviews >= 3
Chế độ đặc trưng	no_text_no_group_no_topic
Nhóm đặc trưng sử dụng	rating, sentiment, evaluation categories, aspect, country diversity
Phương pháp chuẩn hóa	RobustScaler
Số đặc trưng trước PCA	54
Số thành phần PCA	8
Tỷ lệ phương sai giữ lại	0,7405
Thuật toán cuối	KMeans
Số cụm cuối	3

Bảng 4.2. Cấu hình thực nghiệm chính

4.2. Kết quả phân cụm khách sạn

4.2.1. So sánh các thuật toán phân cụm

Các thuật toán KMeans, Agglomerative Clustering, Gaussian Mixture Model và DBSCAN được thử nghiệm trên cùng bộ đặc trưng sau khi chuẩn hóa và giảm chiều. KMeans, Agglomerative Clustering và Gaussian Mixture Model được thử với số cụm từ 2 đến 10. DBSCAN được thử với nhiều giá trị eps và min_samples bằng 5.

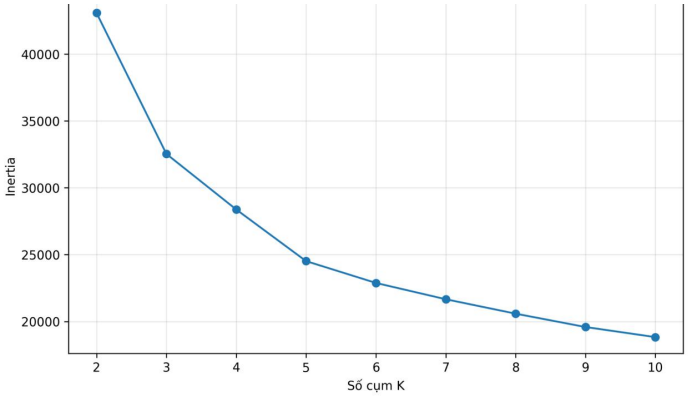
Thuật toán	Số cụm	Inertia	Silhouette	Davies-Bouldin	Calinski-Harabasz
KMeans	3	32532,9752	0,3701	1,2159	791,1883
KMeans	4	28376,5414	0,3712	1,2377	701,7715
KMeans	2	43075,2128	0,3341	1,3775	707,2030
Agglo	4	-----	0,3575	1,2330	605,5564
Agglo	3	-----	0,3408	1,3449	627,3716
Agglo	2	-----	0,3987	1,5541	510,1635
GMM	4	-----	0,2877	1,5196	563,6686
GMM	3	-----	0,2661	1,5297	542,4683

Bảng 4.3. Kết quả so sánh các cấu hình phân cụm tiêu biểu

Bảng 4.3 cho thấy KMeans K = 3 đạt mức cân bằng tốt giữa các chỉ số đánh giá. KMeans K = 4 có Silhouette Score cao hơn nhẹ, nhưng Davies-Bouldin Index tăng và

Calinski-Harabasz Index giảm. Cấu hình KMeans K = 3 được chọn làm mô hình cuối vì giữ được độ tách cụm hợp lý và dễ diễn giải.

4.2.2. Phân tích lựa chọn số cụm K



Hình 4.1. Biểu đồ Elbow của KMeans

Biểu đồ Elbow cho thấy Inertia giảm mạnh khi số cụm tăng từ 2 lên 3. Sau K = 3, đường giảm vẫn tiếp tục nhưng tốc độ giảm chậm hơn. Xu hướng này ủng hộ lựa chọn K = 3, vì số cụm này cân bằng giữa độ chặt của cụm và độ dài phần diễn giải.

4.2.3. Cấu hình mô hình phân cụm cuối

Từ kết quả so sánh, mô hình cuối được chọn là KMeans với K = 3. Dữ liệu đầu vào gồm 54 đặc trưng, được chuẩn hóa bằng RobustScaler và giảm chiều bằng PCA xuống 8 thành phần chính.

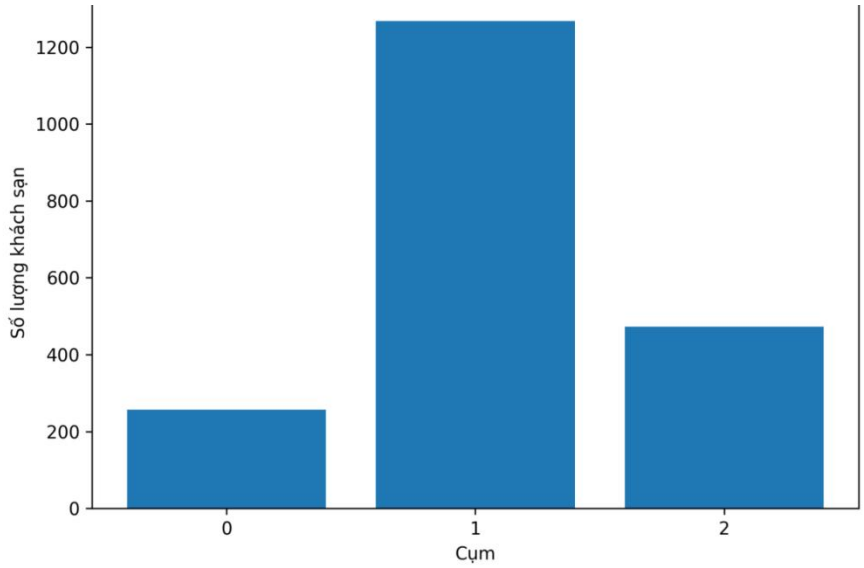
Nội dung	Giá trị
Thuật toán	KMeans
Số cụm	3
Điều kiện lọc khách sạn	num_reviews >= 3
Chế độ đặc trưng	no_text_no_group_no_topic
Phương pháp chuẩn hóa	RobustScaler
Số đặc trưng trước PCA	54
Số thành phần PCA	8
Tỷ lệ phương sai giữ lại của PCA	0,7405
Silhouette Score	0,3701
Davies-Bouldin Index	1,2159
Calinski-Harabasz Index	791,1883

Bảng 4.4. Cấu hình mô hình phân cụm cuối

PCA = 8 giúp giảm số chiều từ 54 đặc trưng xuống 8 thành phần chính. Tỷ lệ phương sai giữ lại đạt 0,7405, tương đương 74,05%. Mức này cho thấy dữ liệu sau giảm chiều vẫn giữ phần lớn biến thiên của bộ đặc trưng, đồng thời làm không gian phân cụm gọn hơn.

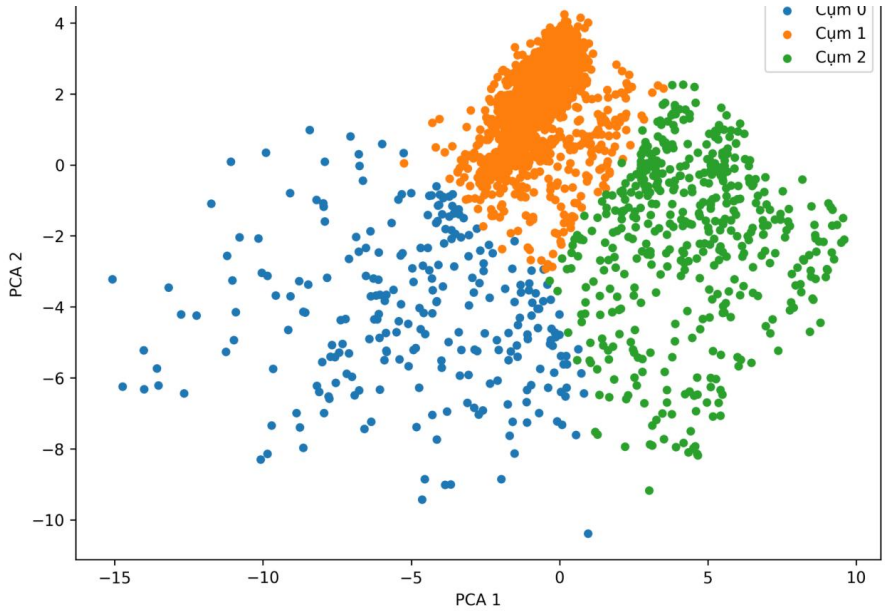
KMeans với K = 3 được chọn vì kết quả ổn định khi xét đồng thời nhiều chỉ số. So với K = 4, K = 3 có Silhouette Score thấp hơn rất ít nhưng Davies-Bouldin Index thấp hơn và Calinski-Harabasz Index cao hơn. K = 3 cũng phù hợp với mục tiêu diễn giải vì tạo ra ba nhóm khách sạn có thể phân tích theo mức độ phản hồi của khách hàng.

4.2.4. Trực quan hóa kết quả phân cụm



Hình 4.2. Số lượng khách sạn theo cụm

Hình 4.2 cho thấy cụm 1 có số lượng khách sạn lớn nhất, tiếp theo là cụm 2 và cụm 0. Phân bố này cho thấy phần lớn khách sạn trong tập dữ liệu thuộc nhóm có đặc điểm trung gian, trong khi nhóm có phản hồi thấp hơn chiếm tỷ lệ nhỏ hơn.



Hình 4.3. Trực quan hóa cụm trên không gian PCA 2D

Hình 4.3 biểu diễn các khách sạn trên không gian hai chiều sau PCA, trong đó mỗi điểm là một khách sạn và màu sắc thể hiện nhãn cụm. Hình này dùng để minh họa tương quan vị trí giữa các nhóm khách sạn. Mô hình phân cụm được huấn luyện trên 8 thành phần PCA, nên hình 2D đóng vai trò trực quan hóa kết quả.

4.3. Diễn giải đặc điểm các cụm khách sạn

4.3.1. Hồ sơ tổng quan của từng cụm

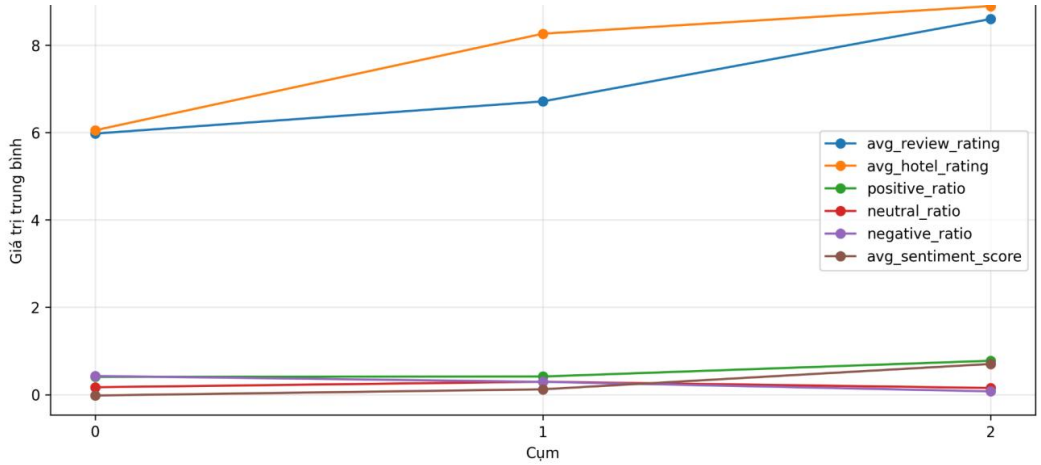
Sau khi có nhãn cụm, từng cụm được phân tích lại bằng các đặc trưng gốc. Các thông tin được dùng để diễn giải gồm điểm review trung bình, rating khách sạn, tỷ lệ sentiment, độ đa dạng quốc gia và các tiêu chí dịch vụ như nhân viên, vệ sinh, vị trí và mức độ đáng tiền.

Cụm	Số KS	Review TB	Rating KS TB	Tích cực	Trung lập	Tiêu cực	Sentiment TB
0	257	5,9754	6,0514	0,4056	0,1685	0,4260	-0,0204
1	1.268	6,7125	8,2623	0,4137	0,2941	0,2922	0,1215
2	473	8,5981	8,8937	0,7752	0,1513	0,0735	0,7017

Bảng 4.5. Hồ sơ trung bình của từng cụm

Bảng 4.5 cho thấy cụm 0 có điểm review trung bình thấp nhất và tỷ lệ tiêu cực cao nhất. Cụm 1 có số lượng khách sạn lớn nhất, điểm review ở mức trung bình và tỷ lệ sentiment không nghiêng mạnh về một phía. Cụm 2 có điểm review trung bình cao nhất, tỷ lệ tích cực cao nhất và tỷ lệ tiêu cực thấp nhất.

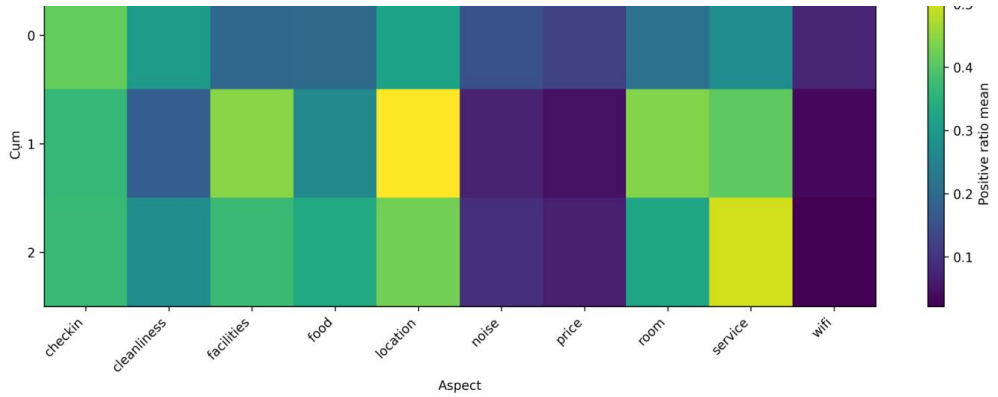
4.3.2. Diễn giải cụm theo sentiment và rating



Hình 4.4. So sánh sentiment và rating giữa các cụm

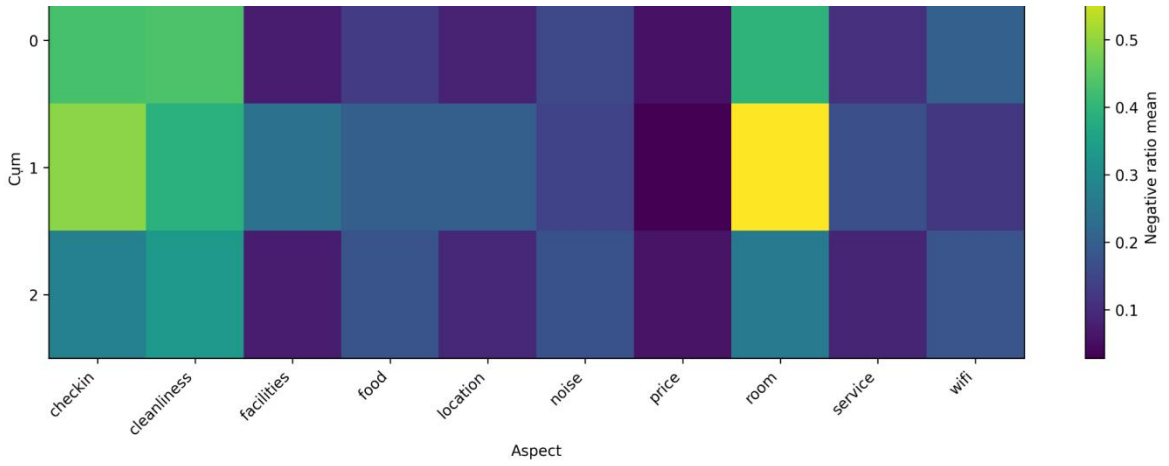
Hình 4.4 cho thấy điểm review trung bình, rating khách sạn và điểm sentiment trung bình tăng dần từ cụm 0 đến cụm 2. Cụm 2 có tỷ lệ review tích cực cao hơn rõ so với hai cụm còn lại. Cụm 0 có tỷ lệ tiêu cực cao, phù hợp với điểm review trung bình thấp trong Bảng 4.5. Các chỉ số trong hình có thang đo khác nhau, vì vậy phần nhận xét được đối chiếu cùng bảng hồ sơ cụm.

4.3.3. Diễn giải cụm theo aspect



Hình 4.5. Heatmap aspect được khen theo cụm

Hình 4.5 cho thấy các aspect được khen thay đổi theo từng cụm. Cụm 2 có mức khen cao ở service, location và facilities. Cụm 1 nổi bật ở location, facilities và room. Cụm 0 có mức khen thấp hơn ở nhiều aspect, nhưng vẫn ghi nhận điểm tốt ở checkin, location và service.



Hình 4.6. Heatmap aspect bị chê theo cụm

Hình 4.6 cho thấy room, cleanliness, checkin và wifi là các aspect cần chú ý ở một số cụm. Cụm 0 bị chê nhiều hơn ở room, cleanliness và wifi. Cụm 1 có mức phàn nàn cao ở room, cleanliness và checkin. Cụm 2 có phản hồi tốt hơn về tổng thể, nhưng wifi và noise vẫn là những điểm cần theo dõi.

Cụm	Aspect mạnh	Aspect yếu
0	location (0.234), service (0.163), facilities (0.123), food (0.073), price (0.067)	room (-0.180), cleanliness (-0.129), wifi (-0.126), checkin (-0.013), noise (-0.001)
1	location (0.337), service (0.241), facilities (0.204), food (0.064), price (0.017)	cleanliness (-0.215), room (-0.153), checkin (-0.130), wifi (-0.087), noise (-0.069)
2	service (0.413), location (0.337), facilities (0.300), food (0.161), checkin (0.095)	wifi (-0.155), noise (-0.078), cleanliness (-0.060), price (0.008), room (0.066)

Bảng 4.6. Điểm mạnh và điểm yếu của từng cụm theo aspect

4.3.4. Tóm tắt ý nghĩa các cụm

Mỗi cụm được mô tả dựa trên điểm review, sentiment, tiêu chí dịch vụ và aspect. Việc đặt tên cụm dựa trên hồ sơ trung bình của cụm và các aspect được khen, chê nổi bật.

Cụm	Tên diễn giải	Ý nghĩa chính
0	Nhóm phản hồi thấp và còn nhiều phàn nàn	Điểm review trung bình thấp nhất, tỷ lệ tiêu cực cao hơn tích cực. Cụm này cần chú ý đến phòng, vệ sinh và wifi.
1	Nhóm trải nghiệm trung bình	Số khách sạn lớn nhất, điểm review ở mức giữa. Cụm này có lợi thế về vị trí và dịch vụ, nhưng còn hạn chế ở vệ sinh, phòng và check-in.
2	Nhóm phản hồi tích cực	Điểm review và tỷ lệ tích cực cao nhất. Cụm này được đánh giá tốt ở dịch vụ, vị trí và tiện nghi, nhưng wifi và tiếng ồn vẫn cần theo dõi.

Bảng 4.7. Tóm tắt ý nghĩa các cụm khách sạn

4.4. Nhận xét chung về kết quả thực nghiệm

Kết quả thực nghiệm cho thấy quy trình phân cụm đã kết hợp được nhiều nhóm thông tin, gồm rating, sentiment, tiêu chí dịch vụ, aspect và độ đa dạng quốc gia của khách hàng. Việc dùng RobustScaler giúp giảm ảnh hưởng của các giá trị lớn bất thường. PCA giúp rút gọn bộ đặc trưng từ 54 biến xuống 8 thành phần chính và giữ lại 74,05% phương sai của dữ liệu.

Trong các cấu hình thử nghiệm, KMeans với K = 3 cho kết quả phù hợp hơn khi xét đồng thời các chỉ số và khả năng diễn giải. Ba cụm thu được tạo cơ sở để phân tích khách sạn theo mức độ phản hồi của khách hàng. Phần diễn giải theo sentiment và aspect giúp làm rõ cụm nào có phản hồi tích cực hơn, cụm nào ở mức trung bình và cụm nào còn nhiều phản hồi tiêu cực.

Kết quả đáp ứng mục tiêu của đề tài ở điểm không dừng lại ở nhãn cụm. Các bảng và hình cho thấy mối liên hệ giữa đặc trưng cấp khách sạn, mô hình phân cụm và ý nghĩa của từng nhóm.

CHƯƠNG 5. KẾT LUẬN VÀ KIẾN NGHỊ

5.1. Kết luận

Đề tài đã xây dựng quy trình phân cụm khách sạn từ dữ liệu đánh giá của khách hàng trên Booking.com. Quy trình gồm các bước chính: lưu trữ dữ liệu trong MongoDB, tiền xử lý review, gán sentiment từ rating, tạo embedding bằng Multilingual-E5-Large, gán topic và aspect, xây dựng đặc trưng cấp khách sạn, chuẩn hóa bằng RobustScaler, giảm chiều bằng PCA và phân cụm.

Dữ liệu thực nghiệm gồm 63 tỉnh/thành, 2.325 khách sạn và 18.779 review. Mỗi khách sạn được biểu diễn bằng các nhóm đặc trưng như rating, sentiment, tiêu chí dịch vụ, aspect và độ đa dạng quốc gia của khách hàng. Cách biểu diễn này giúp mô hình phân tích khách sạn theo nhiều góc nhìn, thay vì dựa riêng vào điểm rating trung bình.

Trong thực nghiệm, đề tài đã so sánh KMeans, Agglomerative Clustering, Gaussian Mixture Model và DBSCAN. Mô hình cuối được chọn là KMeans với K = 3. Bộ dữ liệu phân cụm gồm 54 đặc trưng ban đầu, sau đó được giảm xuống 8 thành phần chính bằng PCA, với tỷ lệ phương sai giữ lại đạt 0,7405. Mô hình cuối đạt Silhouette Score 0,3701, Davies-Bouldin Index 1,2159 và Calinski-Harabasz Index 791,1883.

Kết quả phân cụm chia khách sạn thành ba nhóm. Các cụm được diễn giải lại theo rating, sentiment và aspect để nhận diện nhóm khách sạn có phản hồi tích cực, nhóm có trải nghiệm trung bình và nhóm còn nhiều phản hồi tiêu cực. Phần diễn giải theo aspect giúp làm rõ điểm mạnh và điểm yếu của từng nhóm khách sạn, như phòng, vệ sinh, dịch vụ, vị trí, giá cả, wifi, tiếng ồn và check-in.

Nhìn chung, đề tài đã đạt được mục tiêu xây dựng quy trình phân cụm khách sạn dựa trên đặc tính và cảm xúc khách hàng. Kết quả cho thấy việc kết hợp dữ liệu số và dữ liệu văn bản giúp mô tả khách sạn rõ hơn, đồng thời hỗ trợ phân tích các nhóm khách sạn theo trải nghiệm thực tế của khách hàng.

5.2. Hạn chế

Đề tài còn một số hạn chế. Sentiment được suy ra từ điểm rating, chưa phân tích trực tiếp cảm xúc từ nội dung văn bản. Cách làm này ổn định với dữ liệu đa ngôn ngữ, nhưng chưa phản ánh đầy đủ các review có cả nội dung khen và chê trong cùng một phản hồi.

Việc gán aspect dựa trên độ tương đồng embedding giữa review và mô tả aspect. Kết quả còn phụ thuộc vào danh sách aspect, cách mô tả aspect và ngưỡng tương đồng. Một số review ngắn, mơ hồ hoặc chứa nhiều ý trái chiều vẫn khó gán chính xác.

Kết quả phân cụm phụ thuộc vào bộ đặc trưng được chọn. Một số nhóm đặc trưng như topic, độ dài review và nhóm khách chưa được đưa vào cấu hình phân cụm cuối. Vì vậy, kết quả hiện tại phản ánh chủ yếu các đặc trưng liên quan đến rating, sentiment, aspect, tiêu chí dịch vụ và độ đa dạng quốc gia.

5.3. Kiến nghị

Trong hướng phát triển tiếp theo, nghiên cứu nên thử nghiệm mô hình phân tích cảm xúc trực tiếp từ nội dung review để bổ sung cho cách gán sentiment từ rating. Việc này giúp nhận diện tốt hơn các phản hồi có sắc thái trái chiều.

Bước gán aspect cũng nên được kiểm tra trên một tập mẫu có gán nhãn thủ công. Nếu có dữ liệu nhãn, có thể huấn luyện hoặc tinh chỉnh mô hình phân loại aspect riêng cho dữ liệu khách sạn. Cách làm này giúp đánh giá rõ hơn độ chính xác của aspect.

Ngoài ra, nghiên cứu có thể thử thêm các cấu hình đặc trưng khác để kiểm tra ảnh hưởng của topic, nhóm khách và độ dài review đến kết quả phân cụm. Khi có thêm dữ liệu từ nhiều thời điểm hoặc nhiều nền tảng đặt phòng, kết quả phân cụm sẽ có cơ sở so sánh tốt hơn và phản ánh rõ hơn sự khác biệt giữa các nhóm khách sạn.

TÀI LIỆU THAM KHẢO

[1] "2.3. Clustering," scikit-learn. Accessed: May 30, 2026. [Online]. Available: https://scikit-learn/stable/modules/clustering.html

[2] "AgglomerativeClustering," scikit-learn. Accessed: May 30, 2026. [Online]. Available: https://scikit-learn/stable/modules/generated/sklearn.cluster.AgglomerativeClustering.html

[3] "BIRCH: an efficient data clustering method for very large databases: ACM SIGMOD Record: Vol 25, No 2," *ACM SIGMOD Record*, Accessed: May 30, 2026. [Online]. Available: https://dl.acm.org/doi/10.1145/235968.233324

[4] "DBSCAN," scikit-learn. Accessed: May 30, 2026. [Online]. Available: https://scikit-learn/stable/modules/generated/sklearn.cluster.DBSCAN.html

[5] "intfloat/multilingual-e5-large · Hugging Face." Accessed: May 30, 2026. [Online]. Available: https://huggingface.co/intfloat/multilingual-e5-large

[6] N. Muennighoff, N. Tazi, L. Magne, and N. Reimers, "MTEB: Massive Text Embedding Benchmark," in *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, A. Vlachos and I. Augenstein, Eds., Dubrovnik, Croatia: Association for Computational Linguistics, May 2023, pp. 2014–2037. doi: 10.18653/v1/2023.eacl-main.148.

[7] "KMeans," scikit-learn. Accessed: May 30, 2026. [Online]. Available: https://scikit-learn/stable/modules/generated/sklearn.cluster.KMeans.html

[8] "PCA," scikit-learn. Accessed: May 30, 2026. [Online]. Available: https://scikit-learn/stable/modules/generated/sklearn.decomposition.PCA.html

[9] "RobustScaler," scikit-learn. Accessed: May 30, 2026. [Online]. Available: https://scikit-learn/stable/modules/generated/sklearn.preprocessing.RobustScaler.html

[10] B. Liu, *Sentiment Analysis and Opinion Mining*. Springer, 2022. Accessed: May 30, 2026. [Online]. Available: https://www.perlego.com/book/3706873/sentiment-analysis-and-opinion-mining-pdf

[11] A. Ng, M. Jordan, and Y. Weiss, "On Spectral Clustering: Analysis and an algorithm," in *Advances in Neural Information Processing Systems*, MIT Press, 2001. Accessed: May 30, 2026.[Online].Available: https://papers.nips.cc/paper_files/paper/2001/hash/801272ee79cfde7fa5960571fee36b9b-Abstract.html